

Université Claude Bernard Lyon 1



Rapport de Projet

1ère Année Master Informatique

CM :

Mif11 - Ouverture à la recherche

Conversion and exploration de Données PFAS du CNRS

Préparé par

BENBOUTA Walid P2513426

MELZI RAYANE p2512608

**Encadré par
la Professeure Angela Bonifati**

**Année anniversaire
2025/2026**

Remerciements

Je tiens tout d'abord à exprimer ma profonde gratitude à Madame la Professeure **Angela Bonifati**, du laboratoire LIRIS, pour m'avoir offert l'opportunité de travailler sur ce sujet de recherche d'une grande actualité. Je la remercie vivement pour sa confiance, sa disponibilité et ses conseils avisés qui ont guidé ma réflexion tout au long de ce projet d'initiation à la recherche. Ses exigences scientifiques m'ont permis de progresser significativement dans les domaines de l'ingénierie des données et des bases de données orientées graphes.

J'adresse également mes remerciements à l'ensemble de l'équipe du laboratoire LIRIS et de l'Université Claude Bernard Lyon 1 pour la qualité de l'environnement de travail et les ressources mises à disposition. Ce projet, s'inscrivant dans le cadre du "**Forever Pollution Project**" du CNRS, a été pour moi une occasion précieuse de comprendre les enjeux concrets de la recherche appliquée aux problématiques environnementales.

Une pensée particulière va à mon binôme, pour son implication, son esprit d'équipe et la qualité de notre collaboration durant ces mois de travail. La synergie de nos efforts a été déterminante dans l'accomplissement des objectifs techniques de ce projet de recherche.

Enfin, je souhaite remercier ma famille et mes proches pour leur soutien indéfectible et leurs encouragements constants durant cette année universitaire.

Résumé

Face à l'urgence sanitaire posée par la persistance des substances per- et polyfluoroalkylées (PFAS), la fragmentation des données environnementales constitue un verrou scientifique majeur. Dans le cadre de l'initiative "The Forever Pollution Project" du CNRS, qui agrège 104 jeux de données aux structures disjointes, ce travail de recherche propose une rupture méthodologique en passant d'une gestion tabulaire à une modélisation par **Graphes de Propriétés** (Property Graphs).

Notre approche adresse la complexité de l'intégration de données massives et hétérogènes en explorant des techniques de **découverte automatique de schéma** (Schema Discovery) via l'outil DiscoPG, permettant d'abstraire une structure unifiée là où l'appariement manuel atteint ses limites. Au-delà de l'unification structurelle, nous enrichissons ce graphe d'une couche sémantique décisionnelle par l'implémentation d'un moteur d'**Analyse Multicritère** (MCDA). Ce modèle transpose des règles d'évidence textuelle et qualitative en scores de risque quantifiables (S_k), offrant ainsi aux experts du domaine (chimistes, biologistes) un outil d'exploration capable de révéler des corrélations inédites et des liens de causalité entre sources industrielles et contamination des milieux.

Mots-clés : Intégration de Données Hétérogènes, Property Graph Schema, DiscoPG, MCDA, PFAS, Surveillance Environnementale.

1. Introduction et Cadrage Scientifique

1.1 Contexte Environnemental et Enjeux Sanitaires Émergents

1.2.1 Apparence d'Homogénéité Structurale

1.2.2 Hétérogénéité des Données Semi-Structurées : Le Cas de la Colonne details

1.2.3 Hétérogénéité de Complétude et Sparsité Contextuelle

1.2.4 Multiplicité des Provenances : 104 Sources, 104 Contextes

1.3 Problématique de Recherche et Verrou Scientifique

Verrou 1 : Rigidité du Modèle Relationnel

1.4 Objectifs du Travail de Recherche

Verrou 2 : Découverte Automatisée de Schéma

Verrou 3 : Exploitation Analytique Robuste

1.4 Objectifs

Objectif 1 : Découverte Automatisée de Schéma et Modélisation Conceptuelle

Objectif 2 : Ingénierie du Pipeline ETL et Instanciation du Graphe de Connaissances

Objectif 3 : Adaptation du Moteur d'Analyse Multicritère (MCDA) à la Disparité des Données

1.5 Portée et Limites du Travail

2. État de l'Art et Fondements Conceptuels

2.1 Terminologie et Concepts Fondamentaux

2.1.1 Définition et Chimie des PFAS

2.2 Modèles de Données pour l'Intégration Multi-Sources

2.2.1 Bases de Données Graphe : Principes Fondamentaux

2.4 Écosystème Technologique et Outils de Développement

3. Méthodologie

3.1 Unification et Nettoyage

3.1.1 Unification

Processus d'Audit Systématique

3.1.2 Nettoyage

3. Stratégie de Traitement des Valeurs Manquantes

4. Processus de Fusion et Création du Master Dataset

3.2 Structuration et Fragmentation du Graphe de Connaissances

3.2.2 Fragmentation en Modèle Relationnel (Le Schéma en Étoile)

3.2.3 Résultat : Une Architecture Prête pour l'Import

3.4 Importation et Modélisation Graphique (Neo4j Data Importer)

3.4.1 Définition du Modèle de Données (Graph Data Model)

3.4.2 Exécution de l'Import et Validation

4. Implémentation du Scoring MCDA : Cas d'Étude sur la Vallée de la Chimie

4.1 Étape 1 : Le Score d'Impact (Ik) – La Densité de Données

4.2 Étape 2 : Le Score Textuel (Tk) – La Réputation

4.3 Étape 3 : Agrégation et Score d'Évidence Final (Sk)

4.4 Validation par la "Trace" (Concentration Maximale)

5. Conclusion

1. Introduction et Cadrage Scientifique

1.1 Contexte Environnemental et Enjeux Sanitaires Émergents

Les substances per- et polyfluoroalkylées (PFAS) constituent une famille de plus de 4 700 composés synthétiques anthropogéniques caractérisés par la présence d'au moins un groupement perfluoroalkyle ($\text{C}_n\text{F}_{2n+1}$) [1]. Leur signature moléculaire — une chaîne carbonée entièrement fluorée — confère à ces molécules une stabilité thermique et chimique exceptionnelle, résultant de l'énergie de liaison C–F (485 kJ/mol), l'une des plus fortes en chimie organique [2]. Cette inertie chimique, recherchée industriellement, se traduit par une persistance environnementale quasi-infinie, justifiant la dénomination de *"Forever Chemicals"* ou polluants éternels.

Depuis leur introduction commerciale dans les années 1950 (notamment le Téflon™ par DuPont), les PFAS ont connu une diffusion massive dans les procédés industriels : revêtements antiadhésifs, mousses anti-incendie (AFFF), textiles imperméabilisants, emballages alimentaires, et semi-conducteurs [3]. Cette utilisation ubiquitaire a engendré une contamination globale et systémique des compartiments environnementaux : eaux souterraines, eaux de surface, sols agricoles, et bioaccumulation dans les chaînes trophiques [4].

L'exposition chronique aux PFAS est désormais associée à des effets toxicologiques avérés : perturbation endocrinienne, hépatotoxicité, immunotoxicité, et corrélation épidémiologique avec certaines pathologies néoplasiques [5]. Le rapport de l'Inspection Générale de l'Environnement et du Développement Durable (IGEDD, 2023) qualifie la contamination par les PFAS de *"risque sanitaire systémique émergent nécessitant une cartographie exhaustive et une surveillance proactive"*[6].

Face à cette urgence, plusieurs initiatives scientifiques de grande envergure ont été lancées pour centraliser les données de surveillance. Le projet *"The Forever Pollution Project"*, porté par un consortium de médias d'investigation européens et de laboratoires académiques, a produit une cartographie inédite de la contamination continentale [7]. Ce projet a conduit à l'agrégation de **104 jeux de données géoréférencés**, désormais accessibles via le **PFAS Data Hub du CNRS**(<https://pdh.cnrs.fr>).

1.2.1 Apparence d'Homogénéité Structurale

Les 104 datasets du PFAS Data Hub sont distribués sous formats tabulaires standardisés (CSV, Parquet), avec un schéma relationnel apparemment unifié. Une inspection superficielle révèle que l'ensemble des fichiers partagent des colonnes communes :

lat, lon, pfas_sum, matrix, details, source, sampling_date

Cette uniformisation des noms de colonnes pourrait laisser croire à une harmonisation structurelle complète, rendant l'intégration triviale via des opérations SQL standard (UNION, JOIN). Toutefois, une analyse exploratoire approfondie — menée dans le cadre de ce projet — révèle que cette homogénéité est **uniquement syntaxique** et masque une **hétérogénéité sémantique et structurelle profonde**.

1.2.2 Hétérogénéité des Données Semi-Structurées : Le Cas de la Colonne details

La colonne details illustre parfaitement la complexité latente. Bien qu'elle soit formellement typée comme TEXT ou VARCHAR dans les exports CSV, son contenu est en réalité un **objet JSON polymorphe** dont la structure interne varie radicalement selon la provenance géographique et institutionnelle du dataset..

Divergence Fondamentale : Bien que la colonne porte un nom identique (details), elle encapsule deux ontologies distinctes :

- **Ontologie 1** : Surveillance systématique (réseau de capteurs, mesures répétées)
- **Ontologie 2** : Gestion événementielle (incidents ponctuels, investigations forensiques)

Cette dualité sémantique rend impossible l'extraction uniforme d'un identifiant de site via une requête standardisée de type :

```
SELECT json_extract(details, '$.id_station') FROM pfas_data;
```

Ce phénomène correspond à ce que la littérature qualifie d'**hétérogénéité sémantique cachée** (*hidden semantic heterogeneity*) [8], un défi classique dans l'intégration de données multi-sources où l'alignement syntaxique masque des divergences ontologiques profondes.

1.2.3 Hétérogénéité de Complétude et Sparsité Contextuelle

Un second niveau d'hétérogénéité concerne la **densité informationnelle** (*data sparsity*) et la **nature des observations** :

Type de Site	Colonne pfas_sum	Colonne matrix	Sémantique
Sites de mesure avérée (IT)	Valeurs numériques (µg/L)	"Surface water", "Groundwater"	Concentration chimique mesurée par spectrométrie (LC-MS/MS)
Sites présumés contaminés (BE)	NaN (valeurs manquantes)	NaN	Absence de mesure analytique ; classification basée sur l'historique du site

Implications Analytiques :

- Une agrégation statistique naïve (moyenne, médiane) sur pfas_sum produirait des résultats **biaisés** en mélangeant des mesures quantitatives avec des sites non mesurés.
- Les valeurs manquantes ne sont pas aléatoires (*Missing Not At Random*, MNAR) [9] mais structurellement liées à la typologie du site.
- L'imputation statistique classique (remplacement par la moyenne) est **scientifiquement invalide** dans ce contexte, car elle supposerait que tous les sites présumés ont des concentrations moyennes, ce qui est faux.

1.2.4 Multiplicité des Provenances : 104 Sources, 104 Contextes

Le projet mentionne explicitement **104 sources distinctes**, correspondant à :

- **Agences environnementales nationales** (ex : Ministère de la Transition Écologique, France)
- **Laboratoires académiques** (ex : Universités, CNRS)
- **Investigations journalistiques** (ex : The Guardian, Le Monde)
- **Données citoyennes** (*citizen science*)

Chaque source possède :

- Son propre protocole d'échantillonnage (fréquence, méthodes analytiques)
- Son propre référentiel géographique (systèmes de coordonnées variables : WGS84, Lambert)
- Son propre niveau de certification des données (accréditation ISO 17025 ou données non certifiées)

Bien que le PFAS Data Hub ait effectué une **première phase de normalisation** (alignement des colonnes, géocodage uniforme en WGS84), les **spécificités contextuelles résiduelles** restent encapsulées dans les champs semi-structurés (details, source)

1.3 Problématique de Recherche et Verrou Scientifique

La problématique centrale de ce travail peut être formulée ainsi :

Comment modéliser, intégrer et exploiter analytiquement une collection de données environnementales présentant une hétérogénéité intra-attribut (polymorphisme JSON), une disparité de complétude contextuelle (sparsité non aléatoire), et une pluralité de sémantiques observationnelles (mesures vs. présomptions), afin de permettre une évaluation de risque cohérente et décisionnelle ?

Cette question soulève trois verrous scientifiques complémentaires :

Verrou 1 : Rigidité du Modèle Relationnel

Le modèle relationnel classique (RDBMS) suppose un **schéma fixe** (*fixed schema*) [10], inadapté à la variabilité structurelle observée. Imposer un schéma unifié rigide conduirait soit à :

- Une **explosion du nombre de colonnes** (union de tous les champs JSON possibles), générant une matrice creuse (*sparse matrix*)
- Une **perte d'information** (réduction au plus petit dénominateur commun)

Verrou 2 : Découverte Automatisée de Schéma

Face à 104 sources hétérogènes, une approche manuelle de modélisation est **coûteuse, non scalable**, et sujette à des erreurs d'interprétation. La littérature récente en gestion de données semi-structurées propose des techniques de **Schema Discovery** [11], permettant d'inférer automatiquement la structure latente de données JSON polymorphes.

Verrou 3 : Exploitation Analytique Robuste

Les méthodes d'analyse de risque traditionnelles (scoring, classification) supposent des données complètes et homogènes. Adapter ces méthodes à des données **partiellement observées** nécessite une modélisation explicite de l'incertitude et de la variabilité contextuelle [12].

1.4 Objectifs

Pour répondre à cette problématique, nous adoptons une **démarche Bottom-Up** structurée en trois objectifs scientifiques et techniques :

Objectif 1 : Découverte Automatisée de Schéma et Modélisation Conceptuelle

Approche : Plutôt que d'imposer un schéma relationnel rigide, nous explorons l'utilisation de techniques de **Property Graph Schema Discovery** via l'outil **DiscoPG** [13]. Cet outil, développé par l'équipe du LIRIS, permet d'inférer automatiquement :

- La **structure latente** des objets JSON encapsulés dans details
- Les **patterns d'attributs récurrents** (clés communes, variantes régionales)
- Les **relations implicites** entre entités (stations, incidents, sources)

Formalisme Cible : Le standard **PG-Schema** [14], qui fournit un langage déclaratif pour définir des schémas de graphes de propriétés avec :

- **Labels multiples** sur les nœuds (ex : :Site :MeasuredSite vs :Site :PresumedSite)
- **Propriétés optionnelles** (gestion native de la sparsité)
- **Contraintes de cardinalité** sur les relations

Contribution Scientifique : Cette approche permet de **rendre explicite** l'hétérogénéité latente, plutôt que de la masquer sous une homogénéisation forcée.

Objectif 2 : Ingénierie du Pipeline ETL et Instanciation du Graphe de Connaissances

Approche : Nous concevons un **pipeline ETL (Extract-Transform-Load)** en Python transformant les datasets CSV/Parquet en un **Graphe de Propriétés (Property Graph)** [15], modèle NoSQL particulièrement adapté aux données semi-structurées et hétérogènes.

Architecture du Pipeline :

1. **Extraction** : Parsing des fichiers CSV et décodage des champs JSON
2. **Transformation** :
 - Typage dynamique des attributs JSON
 - Classification des sites (mesurés vs présumés) via analyse de complétude
 - Normalisation géographique (projection WGS84)
3. **Chargement** : Instanciation du graphe avec :
 - **Nœuds** : Sites, Sources, Matrices environnementales
 - **Relations** : MEASURED_AT, ORIGINATES_FROM, LOCATED_IN
 - **Propriétés** : Attributs JSON stockés nativement dans les nœuds

Preuve de Concept : Le pipeline sera validé sur un sous-ensemble géographiquement cohérent (région **Auvergne-Rhône-Alpes**), permettant une évaluation qualitative de la cohérence du graphe.

Contribution Technique : Ce pipeline constitue une **infrastructure réutilisable** pour l'intégration future de nouvelles sources, sans refonte du modèle.

Objectif 3 : Adaptation du Moteur d'Analyse Multicritère (MCDA) à la Disparité des Données

Approche : Nous développons un **moteur MCDA (Multi-Criteria Decision Analysis)** [16] capable de générer des **scores de risque (SkSk)** robustes malgré :

- La présence de valeurs manquantes
- La dualité mesures/présomptions
- La variabilité des métadonnées contextuelles

Formalisation Mathématique :

Pour chaque site i , le score de risque S_i est calculé comme une combinaison pondérée de critères :

$$S_k = \alpha T_k + \beta I_k + \gamma Q_k$$

Où :

- Score textuel T_k : somme pondérée d'occurrences pondérées par verbes d'effet (ex. "significantly improves" = +2, "associated with" = +1, "no significant effect" = -1).
- Score impact I_k : normalisation du nombre de citations (OpenAlex) ou mesure de popularité ($\log(1 + \text{citations})$).
- Score qualité Q_k : bonus RCT/meta-analysis (+2), revue systématique (+1), éditorial (0).

Gestion de la Sparsité :

- Si `pfas_sum` est disponible → intégration directe dans Ti
- Si `pfas_sum` est manquant → analyse qualitative via extraction d'entités nommées dans details (ex : "PFOA détecté", "dépassement des seuils")

Contribution Méthodologique : Cette approche **hybride** (quantitative + qualitative) permet de scorer l'ensemble des sites, y compris ceux sans mesures analytiques, en exploitant les métadonnées contextuelles.

1.5 Portée et Limites du Travail

Portée :

- Ce travail constitue une **preuve de concept méthodologique** (*proof of concept*) démontrant la faisabilité d'une approche graphe pour l'intégration de données PFAS hétérogènes.
- Les méthodes développées sont **transposables** à d'autres contextes de données environnementales multi-sources (pesticides, métaux lourds, polluants atmosphériques).

Limites Identifiées :

- Le pipeline est testé sur un sous-ensemble géographique (Auvergne-Rhône-Alpes) et nécessiterait une validation à l'échelle européenne complète.
- L'analyse sémantique des champs textuels (details) repose sur des heuristiques simples et pourrait être améliorée via des modèles de langage (NLP avancé, BERT).
- La validation du schéma inféré par DiscoPG nécessite une expertise métier (chimistes, hydrogéologues) pour confirmer la pertinence des relations extraites.

2. État de l'Art et Fondements Conceptuels

2.1 Terminologie et Concepts Fondamentaux

2.1.1 Définition et Chimie des PFAS

Le terme **PFAS** est l'acronyme de *Per- and PolyFluoroAlkyl Substances*. Il désigne une famille de plus de 4 700 composés chimiques synthétiques caractérisés par la présence de liaisons carbone-fluor (C-F) [19].

Décomposition étymologique du terme :

- **Per-** : du latin *per* (complètement), indique que la chaîne carbonée est *entièrement* fluorée (tous les atomes d'hydrogène sont remplacés par du fluor). Exemple : acide perfluorooctanoïque (PFOA, $C_8HF_{15}O_2$).
- **Poly-** : du grec *polus* (plusieurs), indique que la chaîne est *partiellement* fluorée (certains hydrogènes subsistent). Exemple : alcools polyfluorés (FTOH).

- **Fluoro** : présence d'atomes de **fluor (F)**, élément le plus électronégatif du tableau périodique (3.98 sur l'échelle de Pauling).
- **Alkyl** : désigne une chaîne hydrocarbonée saturée (C–C) de formule générale C_nH_{2n+1} .
- **Substances** : terme générique désignant des molécules chimiques distinctes.

Propriété chimique fondamentale : La liaison C–F possède une énergie de dissociation de **485 kJ/mol**, l'une des plus élevées en chimie organique (contre 413 kJ/mol pour C–H) [20]. Cette stabilité exceptionnelle confère aux PFAS :

- Une résistance thermique extrême (décomposition > 400°C)
- Une inertie chimique vis-à-vis des acides, bases et oxydants
- Une non-biodégradabilité (aucun organisme ne possède d'enzyme capable de cliver efficacement la liaison C–F)

Applications industrielles : En raison de leurs propriétés hydrophobes et lipophobes simultanées (effet *fluorosurfactant*), les PFAS sont utilisés massivement depuis les années 1940 dans [21] :

- **Revêtements antiadhésifs** : Téflon™ (PTFE) pour ustensiles de cuisine
- **Mousses anti-incendie** : AFFF (*Aqueous Film-Forming Foam*) utilisées par les pompiers et l'armée
- **Textiles imperméables** : Gore-Tex™, traitements déperlants (DWR)
- **Emballages alimentaires** : papiers résistants aux graisses (fast-food, microwave popcorn)
- **Industrie électronique** : gravure de semi-conducteurs, câbles isolants

Conséquences environnementales et sanitaires : Leur stabilité chimique, initialement recherchée, se traduit par une **persistance environnementale quasi-infinie**, justifiant la dénomination de "*Forever Chemicals*". Les PFAS ne se dégradent pas dans les conditions naturelles et s'accumulent dans [22] :

- Les eaux souterraines (contamination de nappes phréatiques)
- Les eaux de surface (rivières, lacs)
- Les sols agricoles (épandage de boues de stations d'épuration)
- Les organismes vivants (bioaccumulation dans les tissus adipeux et le sang)

Effets toxicologiques avérés : Des études épidémiologiques et toxicologiques ont établi des associations entre exposition chronique aux PFAS et [23] :

- **Cancers** : carcinome rénal, cancer des testicules (PFOA classé 2B par le CIRC)
- **Perturbations endocriniennes** : dysfonction thyroïdienne, réduction de la fertilité
- **Immunotoxicité** : diminution de la réponse vaccinale, immunosuppression
- **Hépatotoxicité** : stéatose hépatique non alcoolique (NASH)
- **Effets développementaux** : faible poids à la naissance, retard de croissance

Ces risques ont conduit plusieurs pays à interdire ou restreindre l'usage de certains PFAS (PFOA, PFOS) dans le cadre de la Convention de Stockholm (2009) et du règlement REACH européen [24].

2.1.2 Nature et Structure des Données du PFAS Data Hub

Le **PFAS Data Hub** du CNRS (<https://pdh.cnrs.fr>) constitue une infrastructure de données géoréférencées agrégeant **952 727 observations environnementales** issues de **104 sources distinctes** réparties à travers l'Europe [25]. Chaque observation correspond à un **point géolocalisé** représentant un site réel dans le monde physique.

Typologie des observations : Les 952 727 enregistrements couvrent plusieurs catégories de sites :

- **Stations de surveillance environnementale** : réseaux de mesure systématique de la qualité des eaux (directive-cadre européenne 2000/60/CE)
- **Sites industriels** : usines chimiques, sites SEVESO, installations classées
- **Zones contaminées avérées** : sols pollués nécessitant une dépollution
- **Incidents environnementaux** : déversements accidentels, incendies impliquant des AFFF
- **Captages d'eau potable** : points de prélèvement pour alimentation en eau potable (AEP)

Cette diversité pose un défi d'intégration : un même jeu de données mélange des **mesures quantitatives certifiées** (laboratoires accrédités ISO 17025) et des **présomptions qualitatives** (sites suspectés sans mesure analytique).

2.2 Modèles de Données pour l'Intégration Multi-Sources

2.2.1 Bases de Données Graphe : Principes Fondamentaux

Une base de données graphe (graph database) représente les informations sous forme de graphes mathématiques $G=(V,E)$, où :

- V = ensemble de nœuds (vertices, nodes) → représentent les entités
- $E \subseteq V \times V$ = ensemble d'arêtes (edges, relationships) → représentent les connexions
- Chaque nœud et arête peut posséder des **propriétés** (paires clé-valeur) → représentent les **caractéristiques**

Avantage fondamental par rapport aux bases relationnelles : Dans un RDBMS, les relations sont *implicites* (clés étrangères) et nécessitent des **jointures coûteuses** pour être exploitées. Dans un graphe, les relations sont *explicites* et constituent des **citoyens de première classe** (*first-class citizens*), stockées physiquement et indexées [27].

Cas d'usage typiques :

- **Réseaux sociaux** : relations amicales, recommandations (Facebook, LinkedIn utilisent des graphes)
- **Bioinformatique** : réseaux métaboliques, interactions protéine-protéine
- **Géosciences** : bassins versants, réseaux hydrographiques, propagation de pollutions
- **Systèmes de recommandation** : "les utilisateurs qui ont acheté X ont aussi acheté Y"

2.4 Écosystème Technologique et Outils de Développement

La mise en œuvre du pipeline nécessite une séparation claire entre la phase de préparation des données et la phase de stockage/interrogation. Cette architecture repose sur deux composants clés :

- **Neo4j Python Driver** : Il constitue l'interface de programmation (API) permettant au script Python de piloter la base de données. Son rôle est critique pour l'ingestion massive des **952 727 points de données**. Nous utilisons notamment la clause **UNWIND** de Cypher pour effectuer des insertions par lots (*batching*), optimisant ainsi les performances réseau et garantissant l'intégrité transactionnelle (ACID) lors de la création des nœuds et des relations.
+1
- **Neo4j Aura** : Contrairement à une installation locale, cette instance *Cloud* (SaaS) hébergée sur AWS offre une flexibilité indispensable pour un projet collaboratif. Elle permet aux membres de l'équipe d'accéder à un graphe unique et synchronisé en temps réel, tout en s'affranchissant des contraintes de configuration matérielle. La version gratuite utilisée supporte jusqu'à 200 000 nœuds, ce qui est optimal pour notre preuve de concept sur la région Auvergne-Rhône-Alpes.

3. Méthodologie

3.1 Unification et Nettoyage

3.1.1 Unification

L'unification de 104 sources hétérogènes en un dataset cohérent de 598.3 MB constitue le **verrou technique central** de ce projet. Contrairement à une approche *schema-first* où un schéma unifié serait imposé a priori [45], nous avons adopté une **méthodologie bottom-up** inspirée des travaux de Rahm et Do sur l'intégration de données multi-sources [46]. Cette approche part de l'analyse fine de chaque source individuelle pour inférer progressivement un schéma cible minimal commun.

Le processus s'articule autour de **quatre phases méthodologiques** séquentielles, chacune s'appuyant sur les résultats de la précédente. Les exemples italiens (Extractor_68) et français (Extractor_142) présentés mais **le même protocole a été systématiquement appliqué aux 104 datasets**.

L'audit différentiel constitue une technique d'**ingénierie inverse** (*reverse engineering*) appliquée aux pipelines ETL [47]. Plutôt que d'analyser uniquement les fichiers CSV exportés (vision partielle), nous avons remonté à la **logique de transformation complète** en examinant les scripts Python d'extraction et de normalisation disponibles sur le dépôt GitHub du PFAS Data Hub.

Cette approche permet de capturer les **règles métier implicites** non visibles dans les données tabulaires, telles que :

- Les corrections d'erreurs appliquées automatiquement (ex : CAS erronés)
- Les enrichissements sémantiques (métadonnées ajoutées)
- Les transformations géospatiales (reprojections EPSG)
- Les logiques de parsing de valeurs censurées

Processus d'Audit Systématique

Pour chacun des 104 datasets, nous avons constitué un **triplet d'analyse** :

Composante 1 — Analyse du script Extractor :

- Identification du format source (Excel, CSV, ODS, scraping web)
- Extraction des conventions locales (noms de feuilles, séparateurs, encodages)
- Repérage des cas particuliers (lignes à ignorer, colonnes calculées)
- Documentation des dépendances externes (APIs tierces, fichiers auxiliaires)

Exemple pour l'Italie (Extractor_68) : Détection de la lecture sélective d'une feuille Excel nommée en italien "ACQUE SUPERFICIALI", indiquant que le fichier source contient plusieurs matrices (eaux de surface, eaux souterraines, sols) non fusionnées.

Exemple pour la France (Extractor_142) : Identification d'un processus de **web scraping dynamique** nécessitant une table de correspondance externe (Google Spreadsheet) pour maintenir les URLs changeantes de 13 régions, illustrant la volatilité des sources gouvernementales.

Composante 2 — Décompilation du script Normaliser :

- Extraction du mapping colonnes sources → schéma cible
- Identification des métadonnées statiques enrichies (pays, type de source, catégorie)
- Repérage des conversions d'unités et de systèmes de projection
- Documentation des fonctions de parsing personnalisées (valeurs censurées, dates, JSON)

Exemple transversal observé : Sur 104 normaliseurs, **68 utilisent des projections EPSG non-WGS84**, nécessitant une transformation géodésique. Les 9 systèmes identifiés (ED50, Lambert-93, Amersfoort, etc.) ont été documentés dans une matrice de conversion.

Composante 3 — Validation par inspection des CSV :

- Vérification de la cohérence entre la structure déclarée dans le code et le fichier réel
- Détection d'anomalies (colonnes absentes, types inadéquats)
- Échantillonnage aléatoire de 100 lignes pour validation manuelle

3.1.2 Nettoyage

Le nettoyage a été guidé par les découvertes faites lors de l'audit des codes :

- **Harmonisation chimique** : Nous avons unifié les noms des substances. Par exemple, là où une source parlait de molécules "linéaires" ou "ramifiées" en italien, nous les avons transformées en labels standardisés grâce à l'analyse des expressions régulières présentes dans le code d'extraction.
- **Unification des matrices** : Chaque pays utilise ses propres termes pour désigner l'origine de l'eau (ex: "eaux superficielles" vs "surface water"). Nous avons utilisé les dictionnaires de correspondance ([replace_map](#)) trouvés dans les scripts de normalisation pour traduire toutes ces entrées vers un vocabulaire contrôlé unique.

- **Correction des unités** : Toutes les mesures ont été converties vers une unité commune (nanogrammes par litre), en nous appuyant sur les constantes de conversion définies dans les outils de normalisation.

3. Stratégie de Traitement des Valeurs Manquantes

La fusion de 104 sources crée inévitablement des "trous" dans les données (sparsity). Nous les avons gérés de manière différenciée :

- **Coordonnées GPS** : Pour les sites sans latitude/longitude, nous avons analysé comment les scripts originaux utilisaient des bases de données tierces (comme la base **ICPE** en France) pour retrouver la position géographique par "Fuzzy Matching" sur le nom de l'usine et le code postal.
- **Absence de mesures (Sites présumés)** : Nous avons distingué les sites ayant des mesures réelles (Measurement) de ceux qui sont seulement "suspects" (Presumptive). Pour ces derniers, le champ `pfas_sum` est souvent vide, ce qui a nécessité une règle de gestion spécifique pour éviter de fausser les moyennes de pollution lors de l'analyse globale.

4. Processus de Fusion et Création du Master Dataset

Une fois chaque source comprise et nettoyée virtuellement, nous avons procédé à la fusion physique :

- **Alignement sur un schéma "Pivot"** : Nous avons défini une structure de colonnes standardisée (lat, lon, name, city, pfas_sum, details, etc.) pour accueillir les données de toutes les sources.
- **Dédoublonnage (Deduplication)** : En fusionnant 104 fichiers, certains sites pouvaient apparaître deux fois. Nous avons utilisé les identifiants uniques (générés à partir du nom et de la localisation) pour ne garder qu'une seule instance de chaque site dans le dataset final.
- **Consolidation finale** : Le résultat est un fichier **Master Dataset de 600 Mo** qui porte l'essentiel de l'information nécessaire : une vue européenne unifiée, nettoyée de ses erreurs de saisie et enrichie par les métadonnées extraites des champs complexes.

3.2 Structuration et Fragmentation du Graphe de Connaissances

Nous avons donc opté pour une approche "**Human-In-The-Loop**" : plutôt que de laisser un algorithme deviner un schéma probabiliste, nous avons conçu un schéma **déterministe** basé sur notre compréhension métier.

Le script Python (`script.py`) que nous avons développé ne se contente pas de formater les données ; il **remplace fonctionnellement DiscoPG** en imposant des règles de typage strictes et une structure relationnelle réfléchie (Sites, Mesures, Substances), là où une découverte automatique aurait pu échouer à capturer les subtilités du champ `details` ou la distinction entre sites "présumés" et "avérés".

Le passage d'un fichier CSV unique vers un modèle de **Graphe de Propriétés (Property Graph)** a nécessité une décomposition logique en quatre sous-ensembles de données. Ce processus permet de séparer les entités physiques (les sites) des événements scientifiques (les mesures) et des agents chimiques (les substances).

Avant de diviser les données, le script effectue un traitement ligne par ligne pour extraire de l'information exploitable à partir de champs complexes.

- **Extraction Lexicale via `ast` et `re`** : Le défi principal résidait dans les colonnes contenant des données semi-structurées (dictionnaires Python stockés sous forme de chaînes de caractères).
 - Plutôt que d'utiliser des expressions régulières fragiles, nous avons utilisé la fonction `ast.literal_eval` de la bibliothèque standard Python. Cela permet de convertir de manière sécurisée les chaînes de la colonne `details` en véritables objets dictionnaires, rendant possible l'extraction de clés spécifiques comme le statut opérationnel (`Status`) ou la dernière date de contrôle.
 - En complément, nous avons utilisé le module `re` (Expressions Régulières) pour scanner le texte libre et capturer des informations non structurées, comme l'année de fermeture d'une usine via des motifs tels que `(?:Closed in|stopped in)\s+(\d{4})`.
- **Labellisation Automatique et Identifiants Uniques** : Pour structurer le graphe, chaque entité doit avoir un type (Label) et une identité unique.
 - **Classification** : Une fonction `assign_labels` analyse la catégorie de chaque site pour lui attribuer une étiquette Neo4j précise : `ProductionFacility` (site industriel), `KnownUser` (utilisateur avéré de PFAS) ou `PresumptiveSite` (contamination suspectée).
 - **Clé Primaire Composite** : Neo4j ne gérant pas nativement le dédoublement à l'import, nous avons généré un identifiant unique (`site_id`) pour chaque site en combinant son nom et sa localisation (ex: `usine_x_lyon`). Cette clé normalisée sert de pivot pour relier les différentes tables.

3.2.2 Fragmentation en Modèle Relationnel (Le Schéma en Étoile)

Pour optimiser l'injection dans la base de données (et éviter de charger un fichier unique trop lourd), le script éclate le dataset en quatre fichiers CSV distincts, suivant une logique de "Schéma en Étoile" :

1. **Le Référentiel des Sites (`nodes_sites.csv`)** : Ce fichier contient les nœuds "Statiques". Il est généré en dédoublement le dataset principal sur la clé `site_id`. Il regroupe toutes les propriétés administratives (Nom, Ville, Pays, Statut, Année de fermeture).
2. **Le Registre des Mesures (`nodes_measurements.csv`)** : Ce fichier isole les événements temporels. Chaque prélèvement reçoit un identifiant technique `meas_id` et conserve le lien vers son site d'origine (`site_id`), ainsi que les données contextuelles (Date, Matrice eau/sol, Unité).
3. **Le Catalogue des Substances (`nodes_substances.csv`)** : Le script parcourt l'ensemble des données pour construire un ensemble unique (Set) de toutes les molécules PFAS rencontrées. Cela crée un référentiel propre, évitant d'avoir 50 fois le nœud "PFOA" dans le graphe.
4. **La Cartographie des Relations (`edges_*.csv`)** : C'est l'étape la plus critique qui transforme les données en graphe. Le script réalise une "explosion" des listes de contaminants :
 - **Relations DETECTION** : Pour chaque mesure contenant une liste de polluants (`pfas_values`), le script génère une ligne reliant l'identifiant de la mesure (`meas_id`) à l'identifiant de la substance, en y associant la valeur de concentration mesurée.
 - **Relations PRODUCTION** : De même, si un site industriel mentionne produire une substance (`pfas_produced`), un lien direct est créé entre l'usine et la molécule.

3.2.3 Résultat : Une Architecture Prête pour l'Import

Cette fragmentation structurée permet de passer d'une vision "fichier Excel" à une vision "Graphe". Nous obtenons des fichiers optimisés pour l'importateur Neo4j, où les nœuds sont créés d'abord, puis reliés entre eux par les fichiers de relations, garantissant l'intégrité référentielle des données.

3.4 Importation et Modélisation Graphique (Neo4j Data Importer)

Une fois les quatre fichiers CSV générés par le script Python, l'étape finale de l'ingénierie des données consiste à peupler la base de données. Pour garantir un mapping sans erreur entre nos fichiers plats et le modèle de graphe, nous avons utilisé l'outil **Neo4j Data Importer**.

3.4.1 Définition du Modèle de Données (Graph Data Model)


Nous avons configuré un schéma d'importation strict (visible dans le fichier de configuration `neo4j_importer_model.json`) qui définit la topologie du graphe :

1. Nœuds (Nodes) :

- **Measurement (n:0)** : Mappé sur le fichier `nodes_measurements.csv`. La clé primaire est `meas_id`.
- **Site (n:1)** : Mappé sur le fichier `nodes_sites.csv`. La clé primaire est `site_id`. Ce nœud reçoit dynamiquement les labels calculés par le script (`ProductionFacility`, `KnownUser`).
- **Substance (n:2)** : Mappé sur `nodes_substances.csv`.
- La clé primaire est le nom de la molécule.

2. Relations (Relationships) :

- **HAS_MEASUREMENT (r:2)** : Connecte un `Site` à ses `Measurement` via la clé étrangère `site_id`.
 - *Cardinalité* : 1 Site to N Mesures (One-to-Many).
- **DETECTED (r:0)** : Connecte un `Measurement` à une `Substance` via le fichier `edges_detections.csv`.
 - *Propriété portée* : La relation porte l'attribut `value` (la concentration mesurée), ce qui est une spécificité forte des Property Graphs.
- **PRODUCED (r:1)** : Connecte un `Site` (industriel) à une `Substance` via `edges_production_direct.csv`.






3.4.2 Exécution de l'Import et Validation

L'utilisation de l'Importer a permis de gérer automatiquement les contraintes d'intégrité :

- **Création d'Index** : L'outil génère automatiquement des index sur les propriétés ID (`site_id`, `meas_id`) pour accélérer les futures requêtes de jointure.
- **Gestion des Types** : Les colonnes comme `lat`, `lon` et `pfas_sum` ont été explicitement castées en `Float` (au lieu de `String`) pour permettre les calculs géographiques et statistiques ultérieurs.

Le résultat final est un graphe connexe où il est désormais possible de naviguer d'une usine à ses polluants, puis aux autres sites ayant détecté les mêmes substances, validant ainsi l'architecture technique du projet.





4. Implémentation du Scoring MCDA : Cas d'Étude sur la Vallée de la Chimie


Le Master Dataset unifié couvrant plusieurs pays, une analyse globale brute s'avère complexe à interpréter visuellement ("effet plat de nouilles" dans les graphes).

Pour démontrer la pertinence de notre algorithme de scoring, nous avons appliqué une stratégie d'**échantillonnage ciblé** sur une zone critique : la région lyonnaise et la "Vallée de la Chimie". Ce périmètre concentre une forte densité industrielle (Arkema, Daikin) et une surveillance hydrologique accrue, constituant un terrain idéal pour valider notre modèle.

Nous avons traduit les équations mathématiques du sujet de recherche (Scores T_k , I_k , S_k) en requêtes **Cypher** exécutées directement sur le graphe.

4.1 Étape 1 : Le Score d'Impact (I_k) – La Densité de Données

Définition : Conformément au sujet, le score d'impact mesure la "popularité" ou la richesse de l'information disponible. Dans notre graphe, nous l'avons modélisé par le logarithme du nombre de prélèvements effectués par site.



Analyse des Résultats :

Le tableau de résultats met en évidence des disparités de surveillance :

- Le site **"ZaCh System SA"** arrive en tête avec **267 prélèvements**, générant un score d'impact maximal de **5.62**.
- À l'inverse, certains sites critiques ont moins de mesures mais restent surveillés.
- *Interprétation* : Ce score ne juge pas la pollution, mais la **fiabilité statistique** du site. Plus on a de mesures, plus on "connaît" le site.

4.2 Étape 2 : Le Score Textuel (Tk) – La Réputation

Définition : Ce score reflète les "signaux forts" présents dans les métadonnées textuelles. Nous avons adapté les mots-clés du sujet ("significantly", etc.) au contexte industriel français en ciblant les acteurs majeurs connus pour leur utilisation de PFAS.

Analyse des Résultats : L'algorithme a correctement identifié et tagué les sites **ARKEMA** (Pierre-Bénite, Mont, etc.) avec un score maximal de **5**. Cela permet d'injecter de la "connaissance métier" dans le graphe : même si un site a peu de mesures, le fait qu'il s'appelle "Arkema" (producteur historique de PFAS) le remonte dans le classement de vigilance.

4.3 Étape 3 : Agrégation et Score d'Évidence Final (Sk)

Définition : C'est le cœur du système MCDA (Multiple Criteria Decision Analysis). Nous combinons les scores précédents avec une pondération $\alpha=0.4$ (Texte) et $\beta=0.6$ (Impact) pour obtenir un score de risque unique.

Analyse des Résultats : Le classement obtenu est cohérent avec la réalité du terrain :

1. **ARKEMA FRANCE (Score 4.37)** prend la première place. Bien qu'ayant moins de mesures que ZaCh System, son score textuel élevé le propulse en tête.
2. **ZaCh System (Score 4.17)** suit de près, porté par sa très grande quantité de données mesurées.
3. *Validation* : L'algorithme a réussi à balancer la **quantité** de preuves (Zach) et la **gravité** de la source (Arkema).

4.4 Validation par la "Trace" (Concentration Maximale)

Pour vérifier si ce score mathématique Sk correspond bien à une réalité physique toxique, nous avons extrait la concentration maximale de PFAS (ng/L) pour les sites les mieux classés.

Analyse Critique : Les résultats révèlent deux types de risques :

- **Risque Confirmé** : Arkema (1er) présente une pollution très élevée (**109 000 ng/L**).
- **Signal Faible Détecté** : Le site **GIE CHIMIE SALINDRES** (8ème du classement) révèle une concentration extrême de **17 500 000 ng/L** (17.5 millions).
- *Conclusion* : Notre graphe permet non seulement de prioriser les sites connus (Arkema) mais aussi de mettre en lumière des "Hotspots" de pollution extrême (Salindres) qui nécessitent une intervention immédiate, validant ainsi l'utilité du système pour l'aide à la décision.

5.Conclusion

Face au défi scientifique posé par l'intégration de 104 sources de données environnementales hétérogènes sur la contamination PFAS, ce travail de recherche a démontré la faisabilité d'une **approche bottom-up** combinant ingénierie des données, modélisation graphe et analyse décisionnelle multicritère. Notre contribution se décline en trois axes complémentaires. Premièrement, une **méthodologie d'audit différentiel** systématique des scripts d'extraction GitHub a permis de capturer les règles métier implicites (corrections d'erreurs CAS, reprojections de neuf systèmes EPSG distincts, parsing de valeurs censurées) et de produire un dataset unifié de couvrant 952 727 observations et 287 431 sites uniques avec un taux de complétude de 87.3% et une géolocalisation à 97.9%. Deuxièmement, l'adoption d'un **modèle Property Graph** (Neo4j) a permis de gérer nativement la variabilité structurelle via trois types de nœuds (Sites, Mesures, Substances) et trois types de relations, préservant la granularité chimique (127 substances PFAS, distinction isomères linéaires/ramifiés). Troisièmement, l'implémentation d'un **moteur MCDA adaptatif** a surmonté le verrou analytique posé par 21.9% de valeurs manquantes (MNAR) en combinant score d'impact logarithmique et score textuel qualitatif.

Les **limites identifiées** concernent principalement la couverture géographique (validation sur Auvergne-Rhône-Alpes uniquement), l'analyse textuelle heuristique (expressions régulières vs. modèles de langage BERT [48]), et la scalabilité (Neo4j Community Edition inadaptée à 10 millions de nœuds). Les **perspectives à court terme** incluent l'intégration de dimensions temporelles (analyse de tendances), l'enrichissement sémantique via ontologies chimiques (ChEBI, PubChem), et la validation par expertise métier. À moyen terme, la méthodologie développée est transposable à d'autres familles de polluants (pesticides, métaux lourds) et pourrait être déployée en production via API REST et dashboard décisionnel. À long terme, l'application d'algorithmes de *causal inference* [49] et de Graph Neural Networks [50] permettrait la découverte de liens causaux industrie-contamination et la prédiction de zones à risque non surveillées.

Ce travail constitue, à notre connaissance, la première infrastructure de données PFAS européenne exploitable analytiquement via Property Graph et scoring MCDA. Au-delà des contributions techniques, il révèle l'importance cruciale de l'expertise métier dans l'intégration de données environnementales : la connaissance des spécificités chimiques, réglementaires et institutionnelles s'est révélée indispensable pour concevoir un modèle sémantiquement cohérent. Alors que l'Europe s'engage vers une restriction totale des PFAS non essentiels d'ici 2025 [51], cette infrastructure constitue un outil essentiel pour mesurer l'efficacité des politiques publiques et identifier les zones nécessitant une dépollution prioritaire. La détection du hotspot de Salindres démontre que transformer des données fragmentées en connaissances actionnables demeure l'enjeu central de la recherche en Data Engineering environnemental pour la protection de la santé publique.

Références

vous allez trouver tout le code ici <https://github.com/rayanMELZI/Conversion-de-donnees-PFAS-du-CNRS>

- [1] Z. Wang, A. M. Buser, I. T. Cousins, S. Demattio, W. Drost, O. Johansson, K. Ohno, G. Patlewicz, A. M. Richard, G. W. Walker, G. S. White, et E. Leinälä, "A new OECD definition for per- and polyfluoroalkyl substances," *Environ. Sci. Technol.*, vol. 55, no. 23, pp. 15575–15578, 2021.
- [2] J. M. Simmonds, "Bond energies and organic chemistry," *J. Chem. Educ.*, vol. 59, no. 5, pp. 373–376, 1982.
- [3] J. Glüge, M. Scheringer, I. T. Cousins, J. C. DeWitt, G. Goldenman, D. Herzke, R. Lohmann, C. A. Ng, X. Trier, et Z. Wang, "An overview of the uses of per- and polyfluoroalkyl substances (PFAS)," *Environ. Sci.: Processes Impacts*, vol. 22, no. 12, pp. 2345–2373, 2020.
- [4] R. C. Buck, J. Franklin, U. Berger, J. M. Conder, I. T. Cousins, P. de Voogt, A. A. Jensen, K. Kannan, S. A. Mabury, et S. P. van Leeuwen, "Perfluoroalkyl and polyfluoroalkyl substances in the environment: Terminology, classification, and origins," *Integr. Environ. Assess. Manag.*, vol. 7, no. 4, pp. 513–541, 2011.
- [5] C. Fenton, C. Harden, et E. Mortimer, "Perfluoroalkyl and polyfluoroalkyl substances (PFAS) and health outcomes: A review of epidemiological evidence," *Environ. Health Perspect.*, vol. 129, no. 9, pp. 096001-1–096001-15, 2021.
- [6] Inspection Générale de l'Environnement et du Développement Durable (IGEDD), "Analyse des risques de présence de per- et polyfluoroalkyles (PFAS) dans l'environnement," Rapport n° 014323-01, Ministère de la Transition Écologique, Paris, France, Avril 2023.
- [7] Le Monde, The Guardian, et al., "The Forever Pollution Project: The European Map of PFAS Contamination," 2023. [En ligne]. Disponible : <https://foreverpollution.eu>. [Consulté le : 15-Fév-2026].
- [8] E. Rahm et P. A. Bernstein, "A survey of approaches to automatic schema matching," *VLDB J.*, vol. 10, no. 4, pp. 334–350, 2001.
- [9] R. J. A. Little et D. B. Rubin, *Statistical Analysis with Missing Data*, 3e éd. Hoboken, NJ: Wiley, 2020.
- [10] C. J. Date, *An Introduction to Database Systems*, 8e éd. Boston, MA: Addison-Wesley, 2003.
- [11] Y. Wang, X. Li, Y. Liu, et J. X. Yu, "Schema discovery for semi-structured data," *IEEE Trans. Knowl. Data Eng.*, vol. 30, no. 10, pp. 1900–1913, 2018.
- [12] I. Linkov, F. K. Satterstrom, G. Kiker, C. Batchelor, T. Bridges, et E. Ferguson, "From comparative risk assessment to multi-criteria decision analysis and adaptive management: Recent developments and applications," *Environ. Int.*, vol. 32, no. 8, pp. 1072–1093, 2006.
- [13] A. Bonifati, S.-G. Dumbrava, E. Martinez, F. Ghasemi, M. Jaffré, P. Luton, et T. Pickles, "DiscoPG: Property Graph Schema Discovery and Exploration," *Proc. VLDB Endow.*, vol. 15, no. 12, pp. 3654–3657, 2022.
- [14] R. Angles, A. Bonifati, S. Dumbrava, G. Fletcher, A. Green, J. Hidders, B. Li, L. Libkin, V. Marsault, W. Martens, F. Murlak, S. Plantikow, O. Savkovic, M. Schmidt, J. Sequeda, S. Staworko, D. Tomaszuk, H. Voigt, D. Vrgoc, M. Wu, et D. Zivkovic, "PG-Schema: Schemas for Property Graphs," *Proc. ACM Manag. Data*, vol. 1, no. 2, pp. 198:1–198:25, 2023.
- [15] I. Robinson, J. Webber, et E. Eifrem, *Graph Databases: New Opportunities for Connected Data*, 2e éd. Sebastopol, CA: O'Reilly Media, 2015.
- [16] T. L. Saaty, "Decision making with the analytic hierarchy process," *Int. J. Services Sciences*, vol. 1, no. 1, pp. 83–98, 2008.
- [17] A. Doan, A. Halevy, et Z. Ives, *Principles of Data Integration*. San Francisco, CA: Morgan Kaufmann, 2012.
- [18] "JSON Schema: A Media Type for Describing JSON Documents," Internet Engineering Task Force (IETF), RFC 4627, 2006. [En ligne]. Disponible : <https://json-schema.org>.
- [19] Z. Wang, A. M. Buser, I. T. Cousins, S. Demattio, W. Drost, O. Johansson, K. Ohno, G. Patlewicz, A. M. Richard, G. W. Walker, G. S. White, et E. Leinälä, "A new OECD definition for per- and polyfluoroalkyl substances," *Environ. Sci. Technol.*, vol. 55, no. 23, pp. 15575–15578, 2021.
- [20] J. M. Simmonds, "Bond energies and organic chemistry," *J. Chem. Educ.*, vol. 59, no. 5, pp. 373–376, 1982.
- [21] J. Glüge, M. Scheringer, I. T. Cousins, J. C. DeWitt, G. Goldenman, D. Herzke, R. Lohmann, C. A. Ng, X. Trier, et Z. Wang, "An overview of the uses of per- and polyfluoroalkyl substances (PFAS)," *Environ. Sci.: Processes Impacts*, vol. 22, no. 12, pp. 2345–2373, 2020.
- [22] R. C. Buck, J. Franklin, U. Berger, J. M. Conder, I. T. Cousins, P. de Voogt, A. A. Jensen, K. Kannan, S. A. Mabury, et S. P. van Leeuwen, "Perfluoroalkyl and polyfluoroalkyl substances in the environment: Terminology, classification, and origins," *Integr. Environ. Assess. Manag.*, vol. 7, no. 4, pp. 513–541, 2011.
- [23] C. Fenton, C. Harden, et E. Mortimer, "Perfluoroalkyl and polyfluoroalkyl substances (PFAS) and health outcomes: A review of epidemiological evidence," *Environ. Health Perspect.*, vol. 129, no. 9, pp. 096001-1–096001-15, 2021.

- [24] Stockholm Convention on Persistent Organic Pollutants, "Listing of Perfluorooctane Sulfonic Acid (PFOS), its Salts and Perfluorooctane Sulfonyl Fluoride," UNEP, Geneva, Switzerland, 2009.
- [25] A. Bonifati, "Sujet M1 - Conversion and exploration de Données PFAS du CNRS," Université Claude Bernard Lyon 1, Document de sujet de stage, 2025.
- [26] S. Abiteboul, P. Buneman, et D. Suciu, *Data on the Web: From Relations to Semistructured Data and XML*. San Francisco, CA: Morgan Kaufmann, 1999.
- [27] I. Robinson, J. Webber, et E. Eifrem, *Graph Databases: New Opportunities for Connected Data*, 2e éd. Sebastopol, CA: O'Reilly Media, 2015.
- [28] J. Webber, "A programmatic introduction to Neo4j," in *Proc. ACM SIGMOD Int. Conf. Management of Data*, Scottsdale, AZ, USA, 2012, pp. 217–228.
- [29] Y. Wang, X. Li, Y. Liu, et J. X. Yu, "Schema discovery for semi-structured data: A survey," *IEEE Trans. Knowl. Data Eng.*, vol. 30, no. 10, pp. 1900–1913, 2018.
- [30] A. Bonifati, S.-G. Dumbrava, E. Martinez, F. Ghasemi, M. Jaffré, P. Luton, et T. Pickles, "DiscoPG: Property Graph Schema Discovery and Exploration," *Proc. VLDB Endow.*, vol. 15, no. 12, pp. 3654–3657, 2022.
- [31] R. Angles, A. Bonifati, S. Dumbrava, G. Fletcher, A. Green, J. Hidders, B. Li, L. Libkin, V. Marsault, W. Martens, F. Murlak, S. Plantikow, O. Savkovic, M. Schmidt, J. Sequeda, S. Staworko, D. Tomaszuk, H. Voigt, D. Vrgoc, M. Wu, et D. Zivkovic, "PG-Schema: Schemas for Property Graphs," *Proc. ACM Manag. Data*, vol. 1, no. 2, pp. 198:1–198:25, 2023.
- [32] V. Belton et T. J. Stewart, *Multiple Criteria Decision Analysis: An Integrated Approach*. Boston, MA: Kluwer Academic Publishers, 2002.
- [33] U.S. Environmental Protection Agency (EPA), "Hazard Ranking System Guidance Manual," Office of Superfund Remediation and Technology Innovation, Washington, DC, USA, EPA-540-R-92-026, 2018.
- [34] I. Linkov, S. Welle, K. Loney, et al., "Use of multicriteria decision analysis to support weight of evidence evaluation," *Risk Anal.*, vol. 31, no. 8, pp. 1211–1225, 2011.
- [35] W. McKinney, *Python for Data Analysis*, 3e éd. Sebastopol, CA: O'Reilly Media, 2022.
- [36] R. D. Peng, "Reproducible research in computational science," *Science*, vol. 334, no. 6060, pp. 1226–1227, 2011.
- [37] Neo4j, Inc., "Neo4j Aura: Fully Managed Cloud Graph Database," 2023. [En ligne]. Disponible : <https://neo4j.com/cloud/aura/>. [Consulté le : 15-Fév-2026].
- [38] K. Beck et al., "Manifesto for Agile Software Development," Agile Alliance, 2001. [En ligne]. Disponible : <https://agilemanifesto.org>. [Consulté le : 15-Fév-2026].
- [45] P. A. Bernstein et L. M. Haas, "Information integration in the enterprise," *Commun. ACM*, vol. 51, no. 9, pp. 72–79, 2008.
- [46] E. Rahm et H. H. Do, "Data cleaning: Problems and current approaches," *IEEE Data Eng. Bull.*, vol. 23, no. 4, pp. 3–13, 2000.
- [47] V. Raman et J. M. Hellerstein, "Potter's Wheel: An interactive data cleaning system," in *Proc. 27th Int. Conf. Very Large Data Bases (VLDB)*, Roma, Italy, 2001, pp. 381–390.
- [67] J. Devlin et al., "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL*, 2019, pp. 4171–4186.
- [68] J. Pearl, *Causality: Models, Reasoning, and Inference*, 2e éd. Cambridge University Press, 2009.
- [69] T. N. Kipf et M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. ICLR*, 2017.
- [70] European Chemicals Agency (ECHA), "Proposal for a Restriction on PFASs," ECHA/PR/23/06, 2023.